

# Detección del sargazo en la costa Mexicana con redes neuronales convolucionales.

Javier Emilio Bazán Sánchez



## Abstract

Recientemente, las costas del Caribe han experimentado masivas olas de sargazo pelágico con consecuencias negativas tanto ecológica como económicamente. Basado en técnicas de aprendizaje profundo, este estudio propone un algoritmo novedoso para la detección de sargazos pelágicos flotantes y acumulados a lo largo de la costa de Quintana Roo, México. Utilizando arquitecturas de redes neuronales recurrentes y convolucionales, se diseñó una red neuronal profunda (llamada SeaNet) específicamente para detectar estas macroalgas a lo largo de la costa a través del soporte de detección remota. Se creó un nuevo conjunto de datos que incluye valores de píxeles con y sin sargazo para entrenar y probar SeaNet. Se utilizaron imágenes de Aqua-MODIS para construir el conjunto de datos. Después del proceso de aprendizaje, el algoritmo diseñado alcanza un 90% de probabilidad en sus habilidades de clasificación. SeaNet proporciona una nueva visión para detectar con precisión las llegadas de floraciones de algas.

## 1.Introducción

El sargazo pelágico está formado por macroalgas marrones *S. fluitans* y *S. natans*, y constituye ecosistemas flotantes que sirven como hábitats y viveros para especies marinas importantes como tortugas marinas, peces, invertebrados y micro y macro-epifitas[1]. Sin embargo, en los últimos siete años, las costas caribeñas han experimentado cardúmenes masivos atípicos de sargazo pelágico, con abundancias excepcionales para el Caribe mexicano durante los veranos de 2015 y 2018. Se observó una afluencia masiva en numerosas playas del Caribe vinculadas con la acumulación de *Sargassum* spp. (de ahora en adelante Sargazo)[2].

Con las imágenes satelitales MODIS (espectroradiómetro de imágenes de resolución moderada) y MERIS (espectrómetro de imágenes de resolución media), fue posible rastrear un cambio en sus patrones de distribución para identificar una nueva fuente de distribución posible. Para rastrear los patrones de sargazo, Gower, Young & King (2013) utilizaron el índice máximo de clorofila (**MCI**) derivado de las radiaciones de nivel 1 de MERIS y el borde rojo MODIS (**MRE**). Del mismo modo, Sissini et al. (2017) utilizaron imágenes de radiancia

MODIS Aqua 250 m nivel 1 (banda 1, 645 nm; banda 2, 859 nm) para encontrar patrones de distribución de Sargazo.

La biomasa reportada desde 2011 no tiene precedentes[6]. Una diferencia crucial es que el Sargazo no permanece en el océano abierto, sino que se lava en tierra en la costa. La biomasa acumulada ha resultado en condiciones negativas tanto económica como ecológicamente[7].

Esta biomasa excesiva a lo largo de la costa modifica las playas y aumenta la bioerosión . Esto tiene una influencia directa en la industria del turismo , y en función de las cantidades del Sargazo, éstos generan mal olor , interrumpe el acceso a los turistas , e incluso podría tener repercusiones en la salud[8]. El hundimiento del sargazo también puede contribuir al aporte de materia orgánica , a las comunidades poco profundas y de las aguas profundas .La descomposición de la biomasa del sargazo en las playas también puede modificar los procesos físicos , fisiológicos y ecológicos en las comunidades cercanas a la costa de los arrecifes de coral . El flujo modificado de materia orgánica causado por esta perturbación podría tener efectos negativos a diferentes escalas. Los efectos negativos también afectarían el turismo , la pesca local , y los organismos bentónicos[9]. El caso de los arrecifes de coral es relevante , ya que son los ecosistemas marinos más amenazados del mundo y, aunque aún se desconocen todos los impactos ecológicos y se considera que una de las áreas más afectadas por la acumulación de sargazos es el arrecife de coral. El material orgánico excesivo conduce a la turbidez y a la reducción de la luz, causando hipoxia en los pastos marinos y los corales.[10] Esto ha aumentado la mortalidad de los corales y ha dañado los pastos marinos y la fauna asociada. Anualmente alrededor de 10 millones de turistas visitan el Caribe mexicano . La pérdida económica causada por la llegada del Sargazo puede reducir esos beneficios . Solo en 2015, el gobierno estatal invirtió US\$3 millones para eliminar las macroalgas de las zonas turísticas. Más de 4,400 trabajadores fueron contratados. En 2018 , entre junio y agosto, Se gastaron US\$3.1 millones en salarios para 450 trabajadores.

Mediante la radiación espectral que deja el agua o la reflectancia de la superficie, la detección remota ha servido como el medio principal para estudiar los componentes oceánicos suspendidos o disueltos en el agua. El índice de algas flotantes propuesto por Hu ha sido el método principal utilizado en la teledetección para evaluar la presencia / ausencia de algas flotantes en mar abierto. Se han llevado a cabo investigaciones para evaluar y controlar el sargazo pelágico en el Atlántico central occidental, el mar Amarillo, el golfo de México y el mar Caribe. Por otro lado, se han utilizado sensores con varias características espaciales, temporales, espectrales y radiométricas para el estudio del sargazo. El uso de las plataformas Aqua-MODIS, Terra-MODIS e imágenes de Landsat se destaca debido a su amplia cobertura y patrimonio mundial, así como a los conjuntos de datos de acceso abierto. Con respecto a las costas del Golfo de México y el Mar Caribe, presente una metodología para detectar Sargazo en la región noreste de la península de Yucatán aplicando el algoritmo «Bosque aleatorio» a un conjunto de imágenes Landsat 8 previamente seleccionadas. Los estudios anteriores son contribuciones valiosas para la

detección de vegetación flotante como el sargazo pelágico. Sin embargo, ningún estudio ha abordado la probabilidad de presencia de Sargazo a lo largo de la costa del Caribe mexicano. Teniendo en cuenta el daño potencial y los efectos negativos de las floraciones no solo para el turismo, sino también para la salud de los ecosistemas costeros, es de suma importancia desarrollar métodos precisos para detectar los eventos de floración de algas.

*Desde el punto de vista óptico, las aguas oligotróficas de las costas de Quintana Roo son transparentes en condiciones de no sargazo. En 2015 y 2018 debido a la llegada constante de Sargazo, su descomposición causó aguas marrones turbias, que a su vez alteraron los valores de reflectancia de la superficie del agua cerca de la costa*

## **2. Modelos**

### **2.1. Descripción de red neuronal artificial**

Una red neuronal artificial (ANN) es un modelo matemático inspirado en el comportamiento biológico de las neuronas y cómo se organizan. Los ANN son sistemas paralelos masivos con grandes cantidades de procesadores simples interconectados. Un perceptrón de capa única (SLP) es una red de alimentación basada en una función de transferencia de umbral. SLP es el tipo más simple de red neuronal artificial y solo puede clasificar casos separables linealmente. El Perceptrón multicapa (MLP) es una generalización del Perceptrón simple y surgió como consecuencia de las limitaciones de dicha arquitectura en relación con el problema de la separabilidad no lineal. Se mostró que la combinación de varios MLP podría ser una solución adecuada para tratar ciertos problemas no lineales. Las redes neuronales han tenido muchas aplicaciones en diversas áreas de conocimiento, tales como: sistemas de control, negocios, fabricación y medicina para mencionar solo algunos.

### **2.1. Descripción de aprendizaje profundo.**

El Deep Learning (DL) se presentó en la revista Science en 2006. Desde entonces, se han desarrollado múltiples algoritmos, incluida la red neuronal convolucional (CNN), la red neuronal recurrente (RNN), el codificador automático apilado (SAE) y la red de creencias profundas (DBN). Muchas variantes de algoritmos de aprendizaje profundo son una combinación de dos o más de estos algoritmos

### **2.2. Descripción de red neuronal recurrente**

Otro tipo de NN ampliamente utilizado en DL es la red neuronal recurrente (RNN). Un RNN implementa una arquitectura de memoria a corto y largo plazo (LSTM), que hace de RNN una herramienta ideal para modelar y clasificar series de tiempo. El Deep Learning se ha utilizado con éxito en múltiples áreas, como la biomedicina, medicina, predicción de series de tiempo, reconocimiento de voz, visión por computadora, reconocimiento de patrones y teledetección, entre otros.

## **3. Hipótesis**

Este estudio surgió de la siguiente hipótesis: es posible que una Red Neural Profunda (SeaNet) aprenda automáticamente las relaciones entre diferentes reflectancias corregidas ( $\rho_{hot}$  y  $\rho_{hos}$ ) capaces de detectar la presencia de Sargazo sin el uso del índice existente (es decir, NDVI, FAI, AFAI, etc.) de un conjunto de datos debidamente etiquetado. El objetivo principal de este estudio es analizar si es posible detectar el sargazo a lo largo de la costa del Caribe mexicano mediante el uso de datos MODIS y redes de aprendizaje profundo con una precisión de más del 80%. Bajo este punto de vista, se presenta un nuevo algoritmo para la detección del sargazo. Este algoritmo se basa en técnicas DL. Por lo tanto, el objetivo fue clasificar la presencia / ausencia de sargazo pelágico a lo largo de la costa de Quintana Roo, México, utilizando datos NN y MODIS. Este estudio ofrece un desafío para los estudios de detección remota que proporcionan una herramienta capaz de determinar variables que permiten detectar Sargazo píxel por píxel.

#### **4. Metodología**

948 km de costa del estado de Quintana Roo, México, se definió como el área de estudio para probar y desarrollar los algoritmos propuestos. Además, mediante el uso de imágenes satelitales MODIS, también se definió un conjunto de datos que contienen información oficial sobre zonas y fechas con y sin presencia del Sargazo.

##### **4.1. Área de estudio**

Se seleccionó toda la costa de Quintana Roo, ubicada en la zona este de la península de Yucatán, México. Se seleccionaron píxeles MODIS de un kilómetro de tamaño frente a la línea de playa (desde 21.496124 Latitud, -87.546677 Longitud, hasta 18.477211 Latitud, -88.293625 Longitud), bordeando la costa de Quintana Roo. Esta región es el principal destino de vacaciones en México. Además, el área se encuentra donde las llegadas masivas de Sargazo que se registraron en 2015 y 2018[11].

##### **4.2. Conjunto de datos**

Para construir el conjunto de datos, se desarrollaron tres componentes:

- (1) Una lista de sitios y fechas con y sin Sargazo basada en información oficial compilada por el gobierno de Quintana Roo (2018) y el trabajo de campo en 2015 y 2018.
- (2) conjuntos de imágenes de Aqua-MODIS, con y sin Sargazo , para la costa de Quintana Roo en base a la lista de fechas y sitios mencionados anteriormente.
- (3) Se desarrolló el software (extract\_data.py) para agregar la lista de sitios y conjunto de imágenes, que finalmente genera el conjunto de datos.


##### **4.3. Área y fechas de interés.**

La lista de sitios y fechas con y sin Sargazo utilizados en este estudio se construyó de la siguiente manera. Primero, se construyó una lista de píxeles de toda la zona costera del estado de Quintana Roo con una resolución espacial de 1 km. Esta lista de píxeles incluía los

siguientes parámetros: latitud, longitud, posición en el eje x , posición en el eje y , municipio y fecha. Con el soporte del software de la NASA Seadas ( <https://seadas.gsfc.nasa.gov/> ), se seleccionaron píxeles de una imagen AQUA-MODIS con proyección WGS84. Estos 948 píxeles de un kilómetro representaban toda la costa de Quintana Roo. Posteriormente, basado en información oficial del estado de Quintana Roo ( <https://www.qroo.gob.mx/noticias/sargazo>) y el trabajo de campo, los píxeles donde se observó Sargazo fueron etiquetados. El etiquetado se realizó para 29 fechas diferentes. Se encontró un total de 115 píxeles diferentes con Sargazo.

#### **4.4. Selección de imágenes de franjas de Aqua-MODIS**

En base a las llegadas conocidas de Sargazo en la zona costera de Quintana Roo, las imágenes de la franja de Aqua-MODIS también se utilizaron en la construcción del conjunto de datos. Se registraron el día juliano y el tiempo universal coordinado (hora UTC) de todas las imágenes de barrido seleccionadas (con y sin sargazo ) ( <https://lance-modis.eosdis.nasa.gov/cgi-bin/imagery/realtime.cgi> ) y luego los archivos PDS (L0) se descargaron de MODIS OceanData ( <https://oceandata.sci.gsfc.nasa.gov/MODIS-Aqua/L0/> ). En total, se descargaron 80 archivos PSD (42 archivos correspondientes a Sargazo-fechas y 38 archivos sin). Después del procesamiento y la nueva proyección de todos los archivos, se realizó una composición RGB para cada imagen de franja para permitir un control de calidad visual de cada imagen. Debido a la presencia de nubes en el área de interés, se descartaron un total de 19 imágenes (ocho imágenes con Sargazo y once sin). Posteriormente, 30 archivos con Sargazo y 29 archivos sin Sargazo permanecieron como las imágenes utilizadas en el desarrollo del conjunto de datos[12]. No todas las imágenes eran ideales para la capacitación en redes, debido a la excesiva nubosidad.



#### 4.5. Procesamiento de datos

rocesamiento de datos

El procesamiento de datos comenzó con las imágenes de franja (archivos PDS) descargadas del sitio web de datos de color del océano (<https://oceandata.sci.gsfc.nasa.gov/MODIS-Aqua/L0/>). Basado en el software SeaDAS7. 5. 1, el archivo PSD pasa por diferentes niveles de procesamiento para pasar del nivel 0 (L0) al nivel 2 (L2). Primero, se procesó el archivo L0 para obtener el archivo de nivel 1A (L1A). Después de eso, se creó el archivo GEO. Basado en los archivos L1A y GEO, se produjo el archivo de nivel 1B (L1B). A continuación, se creó el producto L2 y luego se volvió a proyectar. Las características de los niveles de procesamiento de datos MODIS se pueden consultar en el sitio web MODIS Nasa (<https://modis.gsfc.nasa.gov/data/dataproduct/>) Utilizando las características de píxel de latitud y longitud y el programa informático interno (extract\_data.py), se extrajeron los datos MODIS de reflectancia de superficie (**rhos**) y de reflectancia de la parte superior de la atmósfera (**rhof**) correspondientes a la zona costera y se utilizaron para construir el conjunto de datos. Las bandas de longitud de onda seleccionadas para este estudio fueron: 412, 469, 555, 645, 859, 1,240 y 2,130 nm. En el Pseudocódigo se muestra el flujo de trabajo de procesamiento.

Pseudocódigo 1 Esquema de procesamiento de datos

---

```
1: base de datos ← vacía
2: para todos los archivos de datos L0 hacer:
3:   L1A ← modis_L1A.py (archivo L0)
4:   GEO ← modis_GEO.py (L1A)
```

```
5: L1B ← modis_L1B.py (L1A , GEO)
6: L2 ← l2gen (L1B)
7: Reproyectado ← gpt.sh (L2)
8: Datos ← extract_data.py (Reproyectado)
9: append_database (Datos)
10: finaliza para
11: devuelve la base de datos
```

---


## 5. Entrenamiento del modelo neuronal.

SeaNet se inspira principalmente en dos tipos de arquitecturas; Redes neuronales convolucionales (CNN) y redes neuronales recurrentes (RNN). Un problema presente en prácticamente todos los modelos de Machine Learning es el sobreajuste, por lo tanto, durante el diseño de la arquitectura propuesta, se prestó especial atención a mantener el equilibrio entre la optimización y la generalización de la red mediante el uso de diferentes mecanismos, como la deserción, la normalización de lotes y la regularización de peso. .

### 5.1 Estructura de los filtros Kernel

La estructura del bloque convolucional está formado por cuatro componentes: capa convolucional, función de activación RELU, normalización de lotes y operación de <<Dropout>>. El objetivo de los bloques convolucionales es extraer de manera eficiente características o patrones del conjunto de datos de entrada. El componente principal del bloque es una capa convolucional de 1D (dimensión uno). Después de realizar numerosas pruebas con diferentes filtros y tamaños, se tomó la decisión de utilizar un total de **[64, 128, 128]** filtros con un tamaño de **[8, 5, 3]**.





## 5.2 Regularización

Con el objetivo de evitar el sobreajuste, se utilizaron tres mecanismos: regularización de abandono, regularización de peso y normalización de lotes. La deserción es una de las técnicas de regularización más eficaces y más utilizadas para las redes neuronales y se utiliza para mejorar el sobreajuste en las redes neuronales. En cada etapa de entrenamiento, los nodos individuales se eliminan de la red con probabilidad  $1 - p$  o se mantienen en la red con probabilidad  $p$ , de modo que queda una red reducida; Los bordes entrantes y salientes a un nodo abandonado también se eliminan.

La regularización del peso es otra forma común de mitigar el sobreajuste. Esto implicó poner restricciones a la complejidad de una red al obligar a sus pesos a tomar solo valores pequeños, haciendo que la distribución de los valores de peso sea más regular. Hay dos tipos de regularización de peso: regularización L1 y L2. **L2** se usó en los bloques convolucionales de SeaNet. *"En L2 se agrega una "magnitud al cuadrado" del coeficiente como término de penalización a la función de pérdida."*

El bloque convolucional utiliza una operación de Normalización de lotes para aumentar el rendimiento de la red. **Batch Normalization** (BN), es una técnica para mejorar el rendimiento y la estabilidad de ANN, que proporciona cualquier capa en una red neuronal con entradas que son cero media / varianza de la unidad. Durante el proceso de aprendizaje, el tipo de inicialización de los pesos podría causar una digresión a los gradientes, lo que significa que los gradientes tienen que compensar los valores atípicos, antes de aprender los pesos para producir los resultados requeridos. BN regulariza este gradiente al normalizar las activaciones en toda la red. *Evita que los pequeños cambios en*



*los parámetros se amplifiquen en cambios más grandes y subóptimos en las activaciones en gradientes.*

### **5.3 Bloques recurrentes**

Otro componente que forma parte de SeaNet son los **bloques recurrentes**. El objetivo principal de estos bloques es proporcionar memoria a SeaNet. Las redes neuronales recurrentes (RNN) son un tipo especial de red neuronal ampliamente utilizado en problemas de predicción en series de tiempo. Dado su diseño, el RNN permite que la información sea recordada por largos períodos y facilita la tarea de hacer estimaciones futuras utilizando registros históricos. A diferencia de las redes neuronales tradicionales, las redes LSTM tienen bloques de memoria neuronal que se conectan a través de capas. Estos bloques de memoria facilitan la tarea de recordar valores por períodos de tiempo largos o cortos. Por lo tanto, el valor almacenado no se reemplaza iterativamente en el tiempo, y el término del gradiente no tiende a desaparecer cuando se aplica la retropropagación durante el proceso de entrenamiento.

Finalmente, como en el caso de los bloques **convolucionales**, los bloques recurrentes también utilizan la normalización por lotes para mejorar el rendimiento de la red. SeaNet consta principalmente de nueve bloques convolucionales y dos bloques recurrentes.

### **5.5 Red neuronal profunda del sargazo:**

Esta arquitectura está compuesta por nueve bloques convolucionales unidimensionales (1D-Conv  $m \times n$ ) con filtros “m” cuyo tamaño es “n”, dos bloques recurrentes (LSTM 64) y finalmente un bloque Denso (clasificación).

SeaNet fue diseñado usando el lenguaje de programación Python versión 3.7.0 y la biblioteca Keras 2.2.4 con TensorFlow 1.10.0 como backend.

### **Resultados y discusión**

El análisis estadístico con la información de las bandas se realizó para evaluar el comportamiento del conjunto de datos actual. A continuación, se investigan dos algoritmos extraídos de la literatura basada en redes neuronales y aprendizaje automático; Estos algoritmos han mostrado buenos resultados cuando se aplican a problemas de clasificación similares a los de la presente investigación. Finalmente, se presenta una tabla comparativa con los resultados de SeaNet y los otros competidores.

### **Análisis estadístico básico**

Cuando se promediaron cada una de las bandas corregidas (rhos y rhot) de los datos generados con y sin Sargazo, se observaron pequeñas diferencias. Solo los promedios correspondientes a las bandas 859 y 1.240 nm fueron mayores en el caso de la presencia de Sargazo. Por lo tanto, se necesita una poderosa herramienta de algoritmo para clasificar eficientemente las pequeñas diferencias entre los valores de cada píxel y así clasificar la

presencia / ausencia de Sargazo . Un análisis estadístico básico de datos muestra por qué 859 y 1.240 nm son las bandas que utiliza el índice **FAI**. A continuación se muestra las medias en el caso de las bandas rhos.

	rhos_412	rhos_469	rhos_555	rhos_555	rhos_555	rhos_1240	rhos_2130
Sin Sargazo	0.131517	0.13489	0.141123	0.124477	0.227052	0.207291	0.085164
Con Sargazo	0.114489	0.12090	0.133097	0.116607	0.247237	0.233480	0.084166

### La media de la banda rhos.

Los valores promedio de la reflectancia de la superficie (rhos), en las diferentes longitudes de onda (  $\lambda$  ), se utilizan para este estudio. Las unidades de las longitudes de onda son nanómetros (nm).

### Perceptrón multicapa

El perceptrón multicapa (MLP) se define como el algoritmo base para la comparación con el resto de las propuestas. El MLP utilizado está compuesto por una capa de entrada, tres capas intermedias u ocultas y la capa de salida. Cada una de las capas intermedias está compuesta por 500 neuronas que usan la unidad lineal rectificada (RELU) como función de activación. Para mejorar la generalización de la red neuronal, se insertó una función de "abandono" con valores de [0.2 0.2 0.3] respectivamente al final de cada una de las capas intermedias. El abandono, aplicado a una capa, consiste en abandonar aleatoriamente (establecer en cero) una serie de características de salida de la capa durante el entrenamiento. Finalmente, la red tiene una capa softmax que se usa ampliamente en la clasificación multicapa de una sola capa. Formalmente, cada uno de los bloques de las capas ocultas se describe como se muestra en Eq.

El MLP se utilizó para realizar la clasificación de todo el conjunto de datos (4515 píxeles MODIS). El conjunto de datos se dividió en dos grupos: un grupo de **entrenamiento** y **prueba**, cada uno con aproximadamente la misma cantidad de datos (ver Tabla 2 ). El proceso de aprendizaje se llevó a cabo durante 3000 épocas, presentando 100 puntos de datos en cada uno (tamaño de lote). Durante el proceso de prueba, se presentó un conjunto de datos que nunca se usó durante todo el proceso de capacitación al MLP para ver la capacidad de generalización. Como se muestra, el MLP tiene un buen nivel de generalización, clasificando correctamente el 83.76% de los puntos de prueba. Existe una gran diferencia entre las curvas de optimización y generalización, que generalmente es un indicador de sobreajuste.

### Red completamente convolucional

Las redes neuronales convolucionales han mostrado un buen desempeño en problemas de clasificación. La diferencia fundamental entre un perceptrón multicapa y una capa de convolución es que las capas MLP aprenden patrones globales en su espacio de características de entrada, mientras que las capas de convolución aprenden patrones locales. El bloque básico de la FCN se compone de un conjunto de filtros que son responsables de la extracción de características del conjunto de datos. RELU se ha utilizado como una función de activación. Al final del bloque, el FCN incorpora un nuevo bloque llamado Batch normalization (BN). La normalización por lotes reduce la cantidad en la que cambian los valores de la unidad oculta (cambio de covarianza). Para aumentar la estabilidad de una red neuronal, BN normaliza la salida de una capa de activación previa restando la media del lote y dividiendo por la desviación estándar del lote,

El FCN utilizado está compuesto por tres bloques convolucionales: el primer bloque de la red está compuesto por 128 filtros con ocho elementos cada uno, la segunda capa está compuesta por 256 filtros con cinco elementos cada uno, y el último bloque está compuesto por 128 filtros con tres elementos cada uno. El objetivo de esta red es extraer de cada uno de los bloques los atributos de los datos, de lo general en particular, lo que resulta en una buena representación de la información contenida en los datos. Con esta representación de los datos, es posible clasificar correctamente la información en diferentes clases. La ecuación describe formalmente cada uno de los bloques de las capas ocultas . (4) .

$$\begin{aligned}y &= W \otimes x + b \\s &= B N(y) \\(3) \\h &= R E L U(S) .\end{aligned}$$

Al igual que el MLP, el FCN se utilizó para realizar la clasificación de todo el conjunto de datos. Con el objetivo de hacer una comparación en términos de igualdad, tanto el conjunto de datos como los parámetros de entrenamiento utilizados para este modelo fueron los mismos que los presentados en el MLP.

### Validación de SeaNet

En la actualidad, existen múltiples métodos de validación para redes neuronales donde la validación cruzada es la más aceptada. La validación cruzada es un método estadístico utilizado para estimar la habilidad de los modelos de aprendizaje automático. La validación cruzada se puede dividir principalmente en dos grupos: validación cruzada exhaustiva y validación cruzada no exhaustiva. Entre los métodos de validación cruzada exhaustiva, se destacan los siguientes: Dejar una validación cruzada (LOOCV), Validación cruzada exhaustiva, Dejar fuera de validación cruzada, mientras que la validación cruzada no

exhaustiva destaca: validación cruzada k-fold, método Holdout y validación de submuestreo aleatorio repetido.

Debido a las características y el tamaño del conjunto de datos utilizado, se eligió k-fold ( $k = 5$ ) como método de validación cruzada de SeaNet con  $k = 5$ . Para llevar a cabo la validación cruzada, el conjunto de datos se dividió en  $k$  partes de que  $k - 1$  partes se usaron como un conjunto de entrenamiento, mientras que la parte restante se usó como un conjunto de validación. En la ecuación (4), se muestran los resultados de la validación cruzada.  $c_i$  expresa el número de clases correctas dentro del conjunto de datos, mientras que  $e_i$  corresponde al número de clases clasificadas correctamente por el modelo.

SeaNet fue entrenado, probado y comparado con el resto de sus competidores. Como en los casos anteriores, se utilizaron los mismos criterios, es decir, el conjunto de datos total se utilizó mediante la validación cruzada k-fold. El algoritmo fue entrenado durante 3.000 épocas con un tamaño de lote de 100 puntos de datos, también se utilizó la misma semilla de números aleatorios utilizada por MLP y FCN. Es importante mencionar que el nivel de optimización de la red fue menor que el de sus competidores, lo que sugiere que si la red se entrena durante un mayor número de épocas, esto podría mejorar y la generalización podría ser mayor. Después del entrenamiento de la red, SeaNet obtuvo un 70% de éxito en los puntos de prueba de clasificación, lo que implica un aumento del 7% con respecto al MLP y del 4.1% con respecto al FNC.

Solo hay pocos estudios de detección de sargazo en las costas del Caribe. Por lo tanto, no existen algoritmos ni metodologías que nos permitan hacer una comparación directa entre nuestra propuesta y otros estudios, sin embargo, se ha calculado el índice FAI para el conjunto de datos utilizado en el presente estudio con el fin de conocer el comportamiento de el conjunto de datos desde el punto de vista de este índice.

Es importante tener en cuenta que el 50% de los datos con Sargazo son menos compactos que los de aquellos sin Sargazo, lo que implica una mayor distribución de los valores dentro de este 50%. La mayor diferencia aparece en los bigotes inferiores del diagrama de caja de Sargazo. Esta diferencia indica que los valores de FAI de Sargazo reflejan un sesgo mayor con respecto a esos puntos sin la presencia de Sargazo. La Tabla 3 muestra los resultados para el cálculo de los valores estadísticos tradicionales realizados en el índice FAI en el conjunto de datos.

### Tabla 3

Índice FAI para el conjunto de datos.

Valores estadísticos de tendencia central del índice FAI, alimentados con el mismo conjunto de datos utilizado para entrenar y probar SeaNet.

Sargazo FAI	FAI sin Sargazo
píxeles 2306	2209

media	0.088595	0.072789
std	0.109495	0.081089
min	-0.845114	-0.845114
25%	0.001938	0.000794
50%	0.087812	0.051965
75%	0.164528	0.134386
max	0.317351	0.315139

La detección del sargazo es un problema complejo, y por esa razón el conjunto de datos tuvo que construirse con información oficial de fechas, sitios y con trabajo de campo. el conjunto de datos es significativo para proporcionar información de detección remota sobre el Sargazo , hasta ahora no disponible para esta región. Por lo tanto, es posible aplicar el conjunto de datos en otras metodologías o para entrenar otros algoritmos. Por lo tanto, para comparar el rendimiento de clasificación de SeaNet, se eligieron dos algoritmos efectivos ( Wang, Yan y Oates, 2017 ).

La detección de sargazo a lo largo de la costa es un desafío para las técnicas convencionales utilizadas en la teledetección. La presencia / ausencia de sargazo en imágenes satelitales a lo largo de la costa no es tan clara como en mar abierto, porque hay varios ecosistemas de transición. En estas condiciones, el alto rendimiento de clasificación de SeaNet permite observar las pequeñas diferencias entre los valores de las bandas utilizadas para la clasificación y determinar la presencia o ausencia de Sargazo en cada píxel con una precisión máxima de 70%. Esto se destaca para un ANN, ya que aumentar la unidad del 1% en la clasificación requiere un diseño e implementación de alto rendimiento.

Tradicionalmente, la detección de materia suspendida en aguas abiertas se logra mediante productos satelitales o mediante índices bien establecidos. Por lo tanto, el presente estudio es innovador, ya que tiene una alta precisión de clasificación de píxeles con presencia / ausencia de Sargazo , utilizando como datos de entrada las bandas corregidas  $\rho_{rs}$  y  $\rho_{hot}$ . La presente investigación mostró que bajo condiciones de alta concentración de Sargazo , como las presentadas a lo largo de la costa de Quintana Roo en 2015 y 2018, fue posible detectar el Sargazo con datos MODIS.

Aunque la costa del Caribe mexicano tiene una gran importancia económica y ecológica, no existe un sistema de monitoreo que contribuya a tomar decisiones frente a las amenazas de llegada masiva de Sargazo . Por lo tanto, el presente trabajo es muy relevante para esta región, ya que ofrece la base para un diseño de sistema de alerta temprana.

SeaNet podría aplicarse a otras áreas costeras de la región del Caribe, por lo que se propone diseñar una red neuronal artificial capaz de detectar Sargazo en aguas abiertas y construir nuevos conjuntos de datos de entrenamiento basados en productos satelitales e índices de vegetación bien establecidos.

## Conclusiones

Basado en las arquitecturas CNN y RNN, SeaNet fue desarrollado específicamente para detectar Sargazo a lo largo de la costa de Quintana Roo.

Hasta donde se sabe, este es el primer método que utiliza el aprendizaje profundo para detectar el sargazo pelágico a lo largo de la costa que considera no solo el sargazo flotante sino también acumulado . Basado en imágenes de hileras de Aqua-MODIS y sitios conocidos y fechas con y sin Sargazo a lo largo de la costa de Quintana Roo, se construyó un conjunto de datos para entrenar y probar todos los algoritmos utilizados en este estudio. Después del proceso de aprendizaje, SeaNet logró un máximo de 72% de probabilidad en la clasificación de píxeles con y sin Sargazo . Además, utilizando el conjunto de datos para el presente estudio, se calculó el índice FAI. Las medidas de tendencia central del índice FAI para datos con y sin Sargazo Son claramente diferentes Sin embargo, ese índice no ofrece un valor de eficiencia porcentual píxel por píxel. Por lo tanto, SeaNet va más allá, ya que ofrece un valor cuantitativo de su propio rendimiento.

Varios estudios han evaluado las amenazas que los ecosistemas costeros del sur de Quintana Roo han sufrido en las últimas décadas[13]. Sin embargo, existe poca información que analice la degradación del hábitat por Sargazo , ya que es un estresante relativamente nuevo que se suma a las amenazas que ya existen en el Caribe. Por lo tanto, un sistema de detección temprana para alertar sobre la llegada masiva de sargazos es sin duda un desafío para la investigación de zonas costeras vulnerables en el Caribe y para la comprensión de las amenazas a estos ecosistemas costeros.

## Referencias

- [1] Rooker, Turner & Holt, 2006 ; Witherington, Hiram y Hardy, 2012
- [2] Gower, Young & King, 2013; van Tussenbroek et al., 2017
- [3] De Széchy et al., 2012; Gower, Young & King, 2013; Sissini et al., 2017
- [4] De Széchy et al., 2012; Maréchal, Hellio & Hu, 2017
- [5]  
<https://www.eluniversal.com.mx/estados/cientificos-alertan-sobre-uso-de-microorganismo-s-para-limpiar-playas-de-qroo>
- [6] Van Tussenbroek et al., 2017; Rodríguez-Martínez, van Tussenbroek & Jordán-Dahlgren, 2016
- [7] Hu et al., 2016; Schell, Goodwin & Siuda, 2015
- [8] Maréchal, Hellio & Hu, 2017
- [9] Wang et al., 2018'
- [10] Franks, Johnson & Ko, 2016; van Tussenbroek et al., 2017; Louime, Fortune & Gervais, 2017
- [11] Van Tussenbroek et al., 2017

**[12]** MODIS-Aqua, 2018